

Mid term project: Image Retrieval

CS5362 Visión por Computador

Diego Randolp Quispe Apaza
Brigitte Rojas Leon
Alvaro Mauricio Garcia Hurtado
Sofía del Pilar Salazar Mendoza
Marcelino Maita Vargas

20 de septiembre de 2026

1. Introducción

2. Marco teórico

2.1. SIFT

SIFT, o Scale-Invariant Feature Transform, propuesto por Lowe [1], detecta y describe puntos de interés locales que se mantienen reconocibles ante cambios de escala, rotación o iluminación. La imagen se convoluciona con núcleos Gaussianos de desviación estándar creciente σ , formando un espacio de escalas,

$$L(x, y, \sigma) = I(x, y) * G(x, y, \sigma)$$

y los puntos de interés se detectan como extremos locales de la Diferencia de Gaussianas,

$$D(x, y, \sigma) = L(x, y, k\sigma) - L(x, y, \sigma)$$

Los candidatos inestables (bajo contraste o sobre bordes rectos) se descartan, y cada key-point restante se describe con un vector de 128 dimensiones basado en histogramas de gradiente orientados, lo que le da a SIFT su invarianza a rotación y escala.

2.2. RootSIFT

Un descriptor SIFT es, en esencia, un histograma de orientaciones de gradiente, y los histogramas no se comparan de forma óptima con distancia Euclidiana: unos pocos bins con valores altos dominan la distancia y opacan diferencias más sutiles en el resto del vector. Arandjelovic y Zisserman [4] propusieron corregir esto reemplazando la distancia Euclidiana por el kernel de Hellinger, pero en lugar de cambiar el algoritmo de comparación, transformaron el descriptor mismo para que la distancia Euclidiana ordinaria sobre el vector transformado produzca el mismo resultado. La transformación, conocida como RootSIFT, consiste en normalizar el descriptor x en norma ℓ_1 y aplicar raíz cuadrada elemento a elemento,

$$\tilde{x} = \sqrt{\frac{x}{\|x\|_1}}$$

seguido de una normalización ℓ_2 . El efecto práctico es atenuar los bins de mayor magnitud y realzar el peso relativo de los bins pequeños, lo que hace la comparación entre descriptores más sensible a la estructura fina del parche.

2.3. HOG

El Histograma de Gradientes Orientados, propuesto por Dalal y Triggs [3], describe una imagen mediante la distribución de direcciones de sus bordes, bajo la idea de que la forma de un objeto queda bien resumida por la orientación local de sus contornos. Para cada píxel se calcula el gradiente mediante diferencias simples, obteniendo su magnitud y orientación,

$$m(x, y) = \sqrt{G_x^2 + G_y^2}, \quad \theta(x, y) = \arctan\left(\frac{G_y}{G_x}\right)$$

La imagen se divide en celdas pequeñas donde cada píxel vota, ponderado por su magnitud, en un histograma de orientaciones; estas celdas se agrupan en bloques solapados que se normalizan conjuntamente, lo que da robustez frente a cambios de iluminación local. El descriptor final es la concatenación de todos los histogramas de bloque normalizados.

2.4. Bag of Visual Words (BoVW)

Bag of Visual Words representa una imagen mediante un histograma de largo fijo, resolviendo el problema de comparar imágenes que producen un número variable de descriptores locales. [2] Para ello se aprende un vocabulario visual $C = \{c_1, \dots, c_K\}$ mediante k-means sobre una muestra de descriptores del dataset, y cada descriptor x de una imagen se asigna a su palabra visual más cercana,

$$q(x) = \arg \min_{c_j \in C} \|x - c_j\|_2^2$$

La imagen se representa entonces como el histograma de frecuencias de sus palabras visuales asignadas. Este histograma puede ponderarse con un esquema *tf-idf*, que penaliza palabras visuales frecuentes en casi toda la base de datos (poco discriminativas) y da más peso a las que aparecen en pocas imágenes,

$$\text{tfidf}_{ij} = h_{ij} \cdot \log \frac{N}{n_j}$$

donde h_{ij} es el conteo de la palabra visual j en la imagen i , N es el número total de imágenes y n_j el número de imágenes donde aparece la palabra j . La limitación principal de BoVW es que descarta por completo la disposición espacial de los descriptores: dos imágenes pueden producir histogramas casi idénticos si comparten patrones locales similares, aunque estén organizados de forma distinta.

2.5. VLAD

Vector of Locally Aggregated Descriptors [5] se apoya, al igual que BoVW, en un vocabulario visual $C = \{c_1, \dots, c_K\}$ aprendido por k-means, pero en lugar de contar cuántos descriptores caen en cada celda, acumula hacia dónde se desvía cada descriptor respecto de su centroide asignado. Para cada palabra visual c_i se suman los residuos de todos los descriptores que le fueron asignados,

$$V_{i,j} = \sum_{x: \text{NN}(x)=c_i} (x_j - c_{i,j})$$

donde j recorre las dimensiones del descriptor local. El vector VLAD completo es la concatenación de los K bloques de residuos, típicamente seguida de una normalización de raíz cuadrada con signo y una normalización ℓ_2 global. Esta construcción conserva información de primer orden sobre cómo se distribuyen los descriptores dentro de cada celda, algo que el simple conteo de BoVW descarta, permitiendo que un vocabulario mucho más pequeño alcance un poder discriminativo comparable. Un refinamiento relevante es la *intra-normalización*: normalizar en ℓ_2 cada

bloque V_i de forma independiente antes de concatenar, lo cual combate el fenómeno de *burstiness*, que es cuando una textura repetitiva dispara la misma palabra visual muchas veces, haciendo que ese bloque domine la distancia final sin ser realmente lo que distingue a la imagen.

2.6. PCA Whitening

Los descriptores globales concatenados y los vectores VLAD de alta dimensión presentan dos problemas para el cálculo de similitud: sus dimensiones están fuertemente correlacionadas entre sí, y tienen varianzas muy distintas entre componentes. El Análisis de Componentes Principales (PCA) con *whitening* [6] resuelve ambos problemas a la vez. Dado un conjunto de vectores centrado, PCA encuentra una base ortogonal P que diagonaliza la matriz de covarianza, ordenando las componentes por su varianza (autovalor) $\lambda_1 \geq \lambda_2 \geq \dots$. Proyectar los datos sobre esta base elimina la correlación entre dimensiones, asimismo el paso de whitening reescala además cada componente proyectada por el inverso de la raíz cuadrada de su autovalor,

$$\hat{X} = \frac{\text{diag}(\lambda_1^{-1/2}, \dots, \lambda_{D'}^{-1/2}) P^\top X}{\left\| \text{diag}(\lambda_1^{-1/2}, \dots, \lambda_{D'}^{-1/2}) P^\top X \right\|}$$

de modo que todas las direcciones del espacio proyectado contribuyan por igual a la distancia final, en lugar de que las direcciones de mayor varianza opaquen a las demás. El procedimiento reduce además la dimensionalidad a D' componentes, acelerando el cálculo de similitud en la etapa de ranking.

2.7. Medidas de similitud

Una vez que cada imagen está representada como un vector de largo fijo, es necesario definir cómo comparar dos vectores para producir un ranking. Para vectores normalizados en ℓ_2 , la similitud coseno es natural, pues mide el ángulo entre dos vectores sin verse afectada por su magnitud,

$$\cos(q, d) = \frac{q^\top d}{\|q\|_2 \|d\|_2}$$

y se reduce a un simple producto punto cuando ambos vectores ya están normalizados. Para histogramas, donde interesa comparar la forma de la distribución más que su magnitud absoluta, es común usar la distancia chi-cuadrado (χ^2), que da más peso relativo a las diferencias entre bins pequeños que la distancia Euclidiana:

$$\chi^2(q, d) = \frac{1}{2} \sum_i \frac{(q_i - d_i)^2}{q_i + d_i + \epsilon}$$

Otras métricas de uso común incluyen la distancia ℓ_1 (suma de diferencias absolutas), la distancia ℓ_2 (Euclidiana estándar), la intersección de histogramas ($\sum_i \min(q_i, d_i)$), que mide directamente cuánta masa de probabilidad comparten dos histogramas, y la similitud de Hellinger.

2.8. Protocolo de evaluación (mAP)

Para comparar sistemas de recuperación de forma objetiva se define un protocolo estándar sobre el ground truth: cada consulta cuenta con un conjunto de imágenes relevantes (positivas) en la base de datos, y el sistema debe recuperarlas en las primeras posiciones del ranking. Dado un ranking completo de la base para una consulta, la precisión en el rango k mide qué fracción de las primeras k imágenes recuperadas son relevantes,

$$\text{Precision@}k = \frac{\#\{\text{imágenes relevantes en el top-}k\}}{k}$$

La Average Precision (AP) de una consulta resume toda la curva precisión-recall en un solo número, promediando la precisión en cada posición donde aparece un acierto:

$$AP = \frac{1}{N} \sum_{k=1}^M P(k) \text{rel}(k)$$

donde N es el número total de imágenes relevantes para esa consulta, M es el número de imágenes recuperadas, $P(k)$ la precisión en el rango k y $\text{rel}(k)$ un indicador que vale 1 si la imagen en el rango k es relevante y 0 en caso contrario. Finalmente, la Mean Average Precision resume el desempeño global del sistema promediando el AP de las Q consultas evaluadas,

$$mAP = \frac{1}{Q} \sum_{i=1}^Q AP_i$$

3. Metodología

3.1. Dataset y preprocesamiento

Se utilizaron los datasets Oxford5k y Paris6k [7], descargados desde el repositorio público `skylord/oxbuildings` de Kaggle y organizados en dos directorios independientes, `data/oxford` y `data/paris`. El ground truth oficial de VGG define 11 landmarks por dataset, cada uno con 5 imágenes de consulta, para un total de 55 queries por dataset. Cada consulta tiene asociado un conjunto de imágenes *good* y *ok*, consideradas positivas con distinto grado de visibilidad del landmark, y un conjunto *junk*, que se excluye del cómputo de precisión por no ser ni claramente positivo ni negativo.

Durante el preprocesamiento se identificaron 20 imágenes de Paris cuyo contenido real es una página de error HTML guardada con extensión `.jpg`, resultado de un fallo de descarga en el dataset original. Estas imágenes no pudieron leerse con `cv2.imread` y se excluyeron de todo procesamiento posterior. Se detectó además una imagen de Oxford, `ashmolean_000214`, para la cual el detector SIFT no encontró ningún keypoint; esta imagen se conservó en el índice con un vector de descriptores vacío para no romper el pipeline posterior.

3.2. Extracción de descriptores locales

Sobre cada imagen se extrajeron keypoints y descriptores SIFT de 128 dimensiones utilizando la implementación de OpenCV (`cv2.SIFT_create`) [1]. El cómputo, al ser intensivo en CPU, se paralelizó entre múltiples procesos, mientras que la escritura del resultado a un único archivo HDF5 se realizó de forma incremental desde el proceso principal, evitando acumular en memoria los descriptores de todas las imágenes a la vez. Las imágenes corruptas identificadas en el preprocesamiento se omitieron de este cómputo, y la imagen sin keypoints detectados se conservó con un vector de descriptores vacío. Los resultados se almacenaron indexados por dataset e identificador de imagen, junto con un índice auxiliar que registra el número de keypoints detectados por imagen.

3.3. Construcción del vocabulario visual y codificación BoVW

A partir de los descriptores extraídos se construyó un vocabulario visual mediante k-means, entrenado sobre una muestra de descriptores tomada *por imagen* (y no de forma global) para evitar sesgar el vocabulario hacia imágenes con mayor densidad de keypoints. Cada descriptor se

asignó a su palabra visual más cercana y cada imagen se representó como el histograma resultante de dichas asignaciones. Se evaluaron variantes con y sin la transformación RootSIFT previa a la asignación, con y sin ponderación tf-idf, y bajo distintas normalizaciones del histograma final (ℓ_1 , ℓ_2 , raíz cuadrada con signo). El tamaño del vocabulario K se trató como hiperparámetro a barrer experimentalmente, tal como se detalla en la Sección 3.9.

3.4. Codificación VLAD

Como alternativa a BoVW, se implementó Vector of Locally Aggregated Descriptors (VLAD) [5], empleando un vocabulario visual *grueso* de tamaño K considerablemente menor al usado en BoVW. Cada imagen se codificó acumulando, para cada palabra visual, el residuo de los descriptores asignados a ella (Sección de Marco Teórico). Se aplicó la transformación RootSIFT antes de la codificación, así como la intra-normalización por bloque descrita en [?], orientada a mitigar el efecto de *burstiness* característico de las fachadas con patrones repetitivos (ventanas, columnas). El orden de las normalizaciones aplicadas fue: normalización por masa (opcional), raíz cuadrada con signo (opcional), intra-normalización por bloque, y normalización ℓ_2 global.

3.5. Extracción de descriptores globales

Como representación complementaria a los descriptores locales, se calcularon descriptores globales de largo fijo directamente sobre los píxeles de cada imagen, sin depender de la detección de keypoints. En particular se implementaron HOG, un histograma de color en espacio HSV, Local Binary Patterns (LBP) y un descriptor tipo GIST basado en un banco de filtros de Gabor (Sección de Marco Teórico). Cada imagen se redimensionó a un tamaño cuadrado fijo antes del cómputo, lo cual introduce una pérdida de la relación de aspecto original pero garantiza que todos los descriptores tengan la misma dimensión. Todos los descriptores admiten una pirámide espacial opcional, que subdivide la imagen en una grilla y concatena los histogramas de cada celda, otorgando al descriptor global una noción aproximada de localización.

3.6. Combinación de representaciones

Se exploraron dos estrategias de combinación. La primera, *fusión temprana*, concatena distintos descriptores globales en un único vector: para ello, cada bloque se normaliza de forma independiente antes de concatenarse, evitando que el bloque de mayor dimensión domine la distancia final por sobre bloques más pequeños. Solo se conservan en la fusión las imágenes presentes simultáneamente en todos los descriptores a combinar, para evitar alinear incorrectamente filas de imágenes distintas. La segunda estrategia, *fusión tardía*, combina en su lugar los *scores* de similitud ya calculados para cada representación, normalizados por consulta al rango $[0, 1]$ antes de sumarse con pesos, lo que permite que cada representación utilice su propia métrica de similitud óptima antes de combinarse.

3.7. Reducción de dimensionalidad

Tanto a los descriptores globales concatenados como a los vectores VLAD de alta dimensión se les aplicó opcionalmente PCA con whitening (Sección de Marco Teórico), con el propósito de decorrelacionar dimensiones y reducir el costo computacional del ranking. La intensidad del whitening se controló mediante un parámetro continuo entre 0 (solo rotación PCA, sin reescalado por varianza) y 0,5 (whitening completo), dado que un whitening completo aplicado con pocas imágenes de entrenamiento por componente retenida amplifica direcciones que en realidad son ruido de muestreo en lugar de señal útil.

3.8. Sistema de recuperación y ranking

Dado un archivo de embeddings —proveniente de BoVW, VLAD, un descriptor global o una combinación de estos— el sistema calcula la similitud entre la representación de la imagen consulta y todas las imágenes de la base de datos, y ordena estas últimas de mayor a menor similitud. Se implementaron múltiples métricas de similitud (Sección de Marco Teórico), seleccionables independientemente de la representación utilizada. Adicionalmente, se implementaron tres técnicas de re-ranking sin supervisión aplicadas después del ranking inicial: expansión de consulta ponderada por similitud (α -weighted Query Expansion), aumento del lado de la base de datos (Database-side Augmentation), y difusión de similitud sobre un grafo k -NN construido a partir de la propia base de datos.

3.9. Protocolo experimental

Todos los experimentos se evaluaron bajo el protocolo estándar de Oxford5k/Paris6k [7], reportando tanto la métrica oficial de Average Precision con interpolación trapezoidal como la fórmula simplificada del enunciado del curso, junto con Precision@ k para $k \in \{1, 5, 10, 20\}$. Cada representación se evaluó de forma independiente variando su normalización y métrica de similitud, y los resultados se agregaron además por landmark y por dataset para identificar patrones de fallo específicos. Para las representaciones con hiperparámetros libres (tamaño de vocabulario en BoVW y VLAD, dimensión final de PCA, pesos de fusión tardía), se realizó un barrido sistemático reportado en la Sección de Experimentos y Resultados.

4. Experimentos y Resultados

5. Discusión

6. Conclusiones

Referencias

- [1] D. G. Lowe, “Distinctive image features from scale-invariant keypoints,” *International Journal of Computer Vision*, vol. 60, no. 2, pp. 91–110, 2004.
- [2] G. Csurka, C. Dance, L. Fan, J. Willamowski, and C. Bray, “Visual categorization with bags of keypoints,” in *Workshop on Statistical Learning in Computer Vision, ECCV*, 2004.
- [3] N. Dalal and B. Triggs, “Histograms of oriented gradients for human detection,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2005.
- [4] R. Arandjelovic and A. Zisserman, “Three things everyone should know to improve object retrieval,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 2911–2918, 2012.
- [5] H. Jégou, M. Douze, C. Schmid, and P. Pérez, “Aggregating local descriptors into a compact image representation,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 3304–3311, 2010.
- [6] H. Jégou and O. Chum, “Negative evidences and co-occurrences in image retrieval: The benefit of PCA and whitening,” in *Proceedings of the European Conference on Computer Vision (ECCV)*, pp. 155–168, Springer, 2012.

- [7] J. Philbin, O. Chum, M. Isard, J. Sivic, and A. Zisserman, “Object retrieval with large vocabularies and fast spatial matching,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2007.