

Recuperación de imágenes de edificios con métodos clásicos

SIFT, BoVW, VLAD y re-ranking sobre Oxford Buildings y Paris Buildings

Diego Quispe Brigitte Rojas Alvaro Garcia Sofia Salazar Marcelino Maita

Visión por Computador
Proyecto 1

20 de septiembre de 2026

SIFT + BoVW es un buen *baseline*, pero pierde la distribución de los descriptores. **VLAD** conserva esa información y el **re-ranking** mejora el orden final del ranking.

oxford / bodleian_1 — AP = 0.9752

QUERY
bodleian_000107



#1 query
bodleian_000107



#2 ok
bodleian_000298



#3 ok
bodleian_000381



#4 ok
bodleian_000108



#5 ok
bodleian_000208



Consulta (izquierda, en azul) y resultados recuperados (verde = relevante) — pipeline final, AP = 0.975

Agenda

- ➊ Problema y dataset
- ➋ Pipeline general
- ➌ SIFT y RootSIFT
- ➍ BoVW y vocabulario visual
- ➎ Representaciones comparadas
- ➏ VLAD y PCA whitening
- ➐ Similitud y re-ranking
- ➑ Evaluación
- ➒ Oxford vs. Paris
- ➓ Casos exitosos y fallos
- ➔ Conclusiones

Problema y dataset

Oxford Buildings

- 5,062 imágenes
- 11 landmarks, 55 queries

Paris Buildings


- 6,412 imágenes
- 11 landmarks, 55 queries

Cada query tiene imagen, *bounding box* y listas good, ok y junk.

Idea clave: La dificultad no es solo encontrar la misma fachada: hay vegetación, cielo, otras fachadas y cambios fuertes de perspectiva.




Pipeline general (1/2): extracción de descriptores



Idea clave: A partir de los mismos descriptores SIFT se construyen dos representaciones: BoVW (conteo) y VLAD (residuos).

Pipeline general (2/2): descriptores globales y ranking



Idea clave: Todos los métodos terminan en un vector de longitud fija: eso permite comparar la consulta contra toda la base y producir un ranking.

SIFT y RootSIFT

- SIFT detecta puntos estables en escala y orientación.
- Cada keypoint: vector de 128 valores.
- Descriptores guardados en HDF5 (no se recalculan).
- RootSIFT: normalización ℓ_1 + raíz cuadrada.

$$x_{\text{root}} = \sqrt{\frac{x}{\|x\|_1}}$$

Por qué SIFT: robusto a escala, rotación y cambios moderados de iluminación.

Limitación: detecta textura irrelevante (hojas, ramas).




BoVW y vocabulario visual

- 1 Muestra de descriptores SIFT.
- 2 K-means aprende K palabras visuales.
- 3 Cada descriptor $\rightarrow$ centroide más cercano.
- 4 Histograma de K posiciones por imagen.

descriptores SIFT $\rightarrow$ palabras visuales
 $\rightarrow [12, 4, 0, 31, \dots]$

Config. recomendada: $K=4096$, RootSIFT,
TF-IDF, norm. ℓ_1



Idea clave: BoVW descarta la posición espacial: dos edificios distintos pueden tener histogramas parecidos si comparten texturas.

Representaciones comparadas (mAP, Oxford)

Representación	Qué conserva	mAP
Color (histograma HSV)	Distribución HSV	0.1049
LBP	Textura	0.1072
GIST	Estructura global	0.1427
HOG	Bordes y forma	0.1467
BoVW $K=4096$	Frecuencia de patrones locales	0.3136
VLAD $K=256$ + PCA	Residuos locales	0.5282
VLAD + DBA + Difusión	Residuos + re-ranking	0.7053

Idea clave: Los descriptores globales son buenos baselines, pero el salto importante ocurre al modelar patrones locales: VLAD supera a BoVW porque conserva más información que un simple conteo.

VLAD y PCA whitening


VLAD acumula el residuo respecto al centroide asignado:

$$v_k = \sum_{x \rightarrow c_k} (x - c_k)$$

- BoVW guarda *cuántos* caen en cada centroide.
- VLAD guarda también *en qué dirección* se alejan.

K	256
RootSIFT	sí
Intra-normalización	sí
PCA	512 dim.
whiten-power	0.25

Idea clave: PCA reduce dimensión y correlación; la intra-normalización evita que una textura repetitiva domine el vector.



Base: similitud coseno entre vectores normalizados.

- **Query Expansion:** incorpora vecinos de la consulta.
- **DBA** ($n=5$): incorpora vecinos a cada vector de la base.
- **Difusión** ($k=100$): propaga similitud por un grafo de vecinos.

Etapas	mAP
VLAD base	0.5282
+ Query Expansion	0.5545
+ DBA	0.5817
+ Difusión	0.6780
+ DBA(5) + Difusión(100), seeds=5	0.7053

Idea clave: La difusión ayuda porque imágenes del mismo edificio forman una cadena de vistas parecidas, aunque dos de ellas no se parezcan directamente.

Precision@k

Fracción de relevantes en los primeros k :

$$\text{Precision@k} = \frac{\text{relevantes en top-}k}{k}$$

AP y mAP

AP: calidad del ranking de una query.

mAP: promedio del AP sobre todas las queries.


```
python 4_evaluate_retrieval.py -embeddings vlad_k256_pca512.npz \  
-name vlad_best -metric cosine -datasets oxford \  
  
-dba 5 -diffusion 100 -diffusion-seeds 5
```

Protocolo:

- Se eliminan las imágenes junk.
- Cada query se evalúa contra su propio dataset.
- Se usa la base completa (no solo top-5) para AP.

Análisis Oxford vs. Paris

Dataset	VLAD base	+DBA+dif.
Oxford	0.5282	0.7053
Paris	0.5514	0.8119
Oxford+Paris	—	0.7586



Idea clave: La mejora no es exclusiva de Oxford: también se observa en Paris, lo que indica que el re-ranking generaliza dentro de este protocolo.

Caso exitoso


oxford / keble_5 — AP = 0.9588



Vistas que comparten estructura de fachada: los patrones locales se mantienen pese al cambio de captura.

Caso de fallo

oxford / christ_church_5 — AP = 0.0220



Vegetación y fondos con textura producen descriptores parecidos a los de otros landmarks.

Idea clave: Magdalen es difícil en casi todas las representaciones. El bbox puede ayudar cuando el edificio ocupa poca área, pero no siempre: eliminar demasiado contexto también perjudica.

- ❶ SIFT es una buena base para edificios: representa patrones locales.
- ❷ BoVW es eficiente, pero pierde información espacial y de residuos.
- ❸ VLAD mejora claramente a BoVW.
- ❹ DBA y difusión mejoran el ranking sin aprendizaje profundo.
- ❺ La evaluación combina mAP, Precision@k y ejemplos visuales.

Trabajo futuro: verificación geométrica (Lowe + RANSAC), uso sistemático del bbox, ASMK/Fisher Vectors, indexación invertida.

Idea clave: Lo importante no es solo que VLAD tenga mayor mAP, sino entender por qué: conserva información que BoVW descarta, y el re-ranking explota la estructura de vecinos del conjunto.

Gracias

Preguntas

Backup: preguntas frecuentes

Por qué BoVW no es suficiente?

Representa la imagen como histograma de frecuencias y pierde *dónde* aparecen los patrones; VLAD conserva el residuo respecto al centroide.

Qué significa K en BoVW/VLAD?

Número de centroides del vocabulario: bins del histograma (BoVW) o bloques de residuos (VLAD).

Por qué un K mayor no siempre es mejor?

Es más discriminativo, pero necesita más memoria y datos por clúster; con pocos descriptores por clúster el vocabulario se vuelve inestable.

Diferencia entre AP y mAP?

AP mide una query; mAP promedia el AP sobre todas las queries.

El resultado puede diferir de otra implementación?

Sí: cambiar las queries, el uso del bbox, el tratamiento de junk o la fórmula de AP altera el mAP.

Todos los modelos deben evaluarse con el mismo protocolo.

El re-ranking usa deep learning?

No. DBA y difusión operan sobre vectores y grafos de similitud: son métodos clásicos y *training-free*.